# Data Science 03: Inženýrství příznaků (Feature Engineering)

In [1]:
```
# Instalace potřebných knihoven
#%pip instal pandas
#%pip install numpy

#%pip install scipy

#%pip install seaborn
```

In [2]:
```
# Import potřebných knihoven
import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns

from scipy import stats

import warnings
warnings.simplefilter(action='ignore', category=FutureWarning)

%matplotlib inline
```

In [3]:
```
# Soubor je načten a přiřazen do proměnné ‚df‘
path='../../data/raw/exploration_timelaps.csv'
df = pd.read_csv(path)
df.head()
```

Out[3]:

| | id | type_brick | time_start | time_verif | time_dest | time_end | time_start_sec | time_verif_sec | time_dest_sec |
|---|---|---|---|---|---|---|---|---|---|
| **0** | 1 | CORNER | 13:52:18 | 13:52:24 | 13:52:42 | 13:52:58 | 49938 | 49944 | 49962 |
| **1** | 2 | HALF | 13:52:58 | 13:53:02 | 13:53:18 | 13:53:36 | 49978 | 49982 | 49998 |
| **2** | 4 | BASIC | 13:56:00 | 13:56:06 | 13:56:20 | 13:56:36 | 50160 | 50166 | 50180 |
| **3** | 6 | BASIC | 13:58:10 | 13:58:16 | 13:58:30 | 13:58:46 | 50290 | 50296 | 50310 |
| **4** | 9 | BASIC | 14:00:34 | 14:00:42 | 14:00:54 | 14:01:18 | 50434 | 50442 | 50454 |

## Analýza vzorců jednotlivých příznaků prostřednictvím grafické vizualizace

### Výpočet korelace mezi proměnnými

In [4]:
```
df[['type', 'start_to_verif', 'verif_to_dest', 'dest_to_end', 'total_time']].corr()
```

Out[4]:

| | type | start_to_verif | verif_to_dest | dest_to_end | total_time |
|---|---|---|---|---|---|
| **type** | 1.000000 | -0.003512 | 0.245297 | -0.054473 | 0.061875 |
| **start_to_verif** | -0.003512 | 1.000000 | -0.287021 | -0.360210 | -0.009296 |
| **verif_to_dest** | 0.245297 | -0.287021 | 1.000000 | 0.000781 | 0.342666 |
| **dest_to_end** | -0.054473 | -0.360210 | 0.000781 | 1.000000 | 0.831654 |
| **total_time** | 0.061875 | -0.009296 | 0.342666 | 0.831654 | 1.000000 |

In [5]:
```
# 'dest_to_end' jako potenciální prediktor 'total_time'
sns.regplot(x="dest_to_end", y="total_time", data=df)
plt.ylim(0,)
```

Out[5]:
```
(0.0, 66.09946446883836)
```

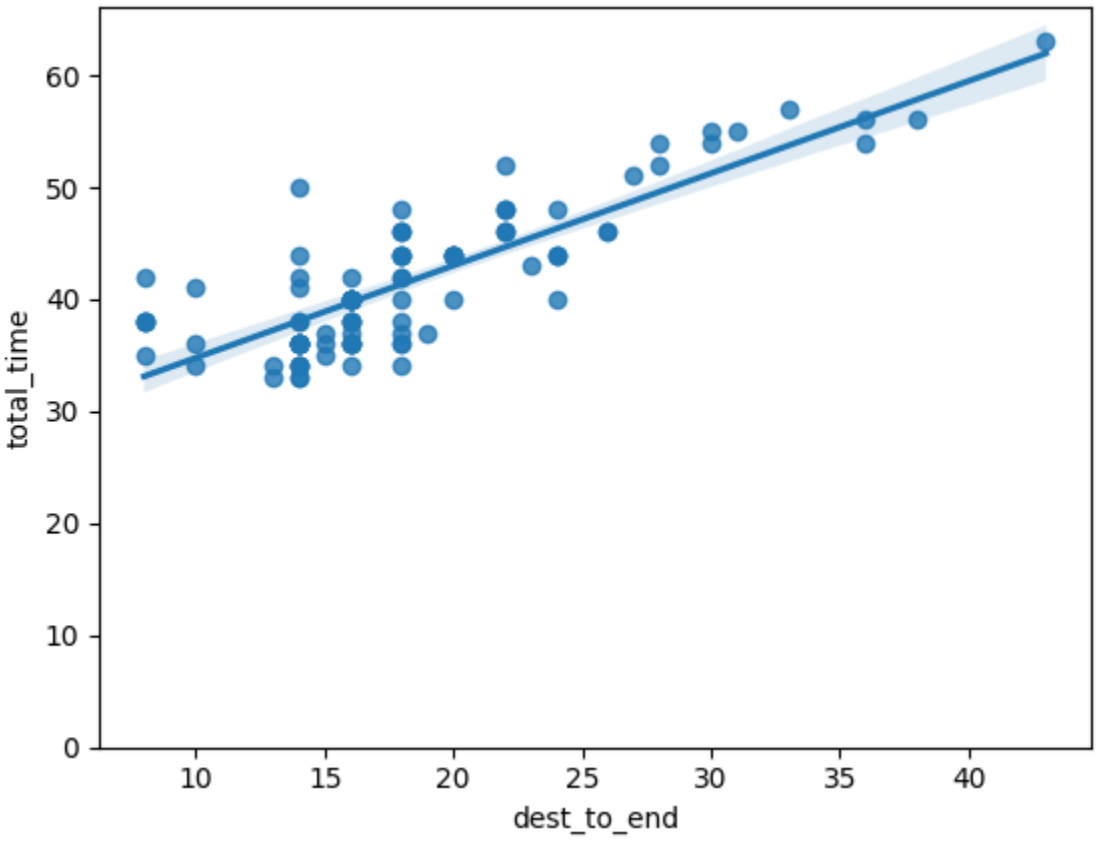


## Analýza kategorických proměnných

In [6]:
```
# Vztah mezi proměnnými ‚type‘ a ‚total_time‘
sns.boxplot(x='type_brick', y="total_time", data=df)
```

Out[6]:
```
<Axes: xlabel='type_brick', ylabel='total_time'>
```

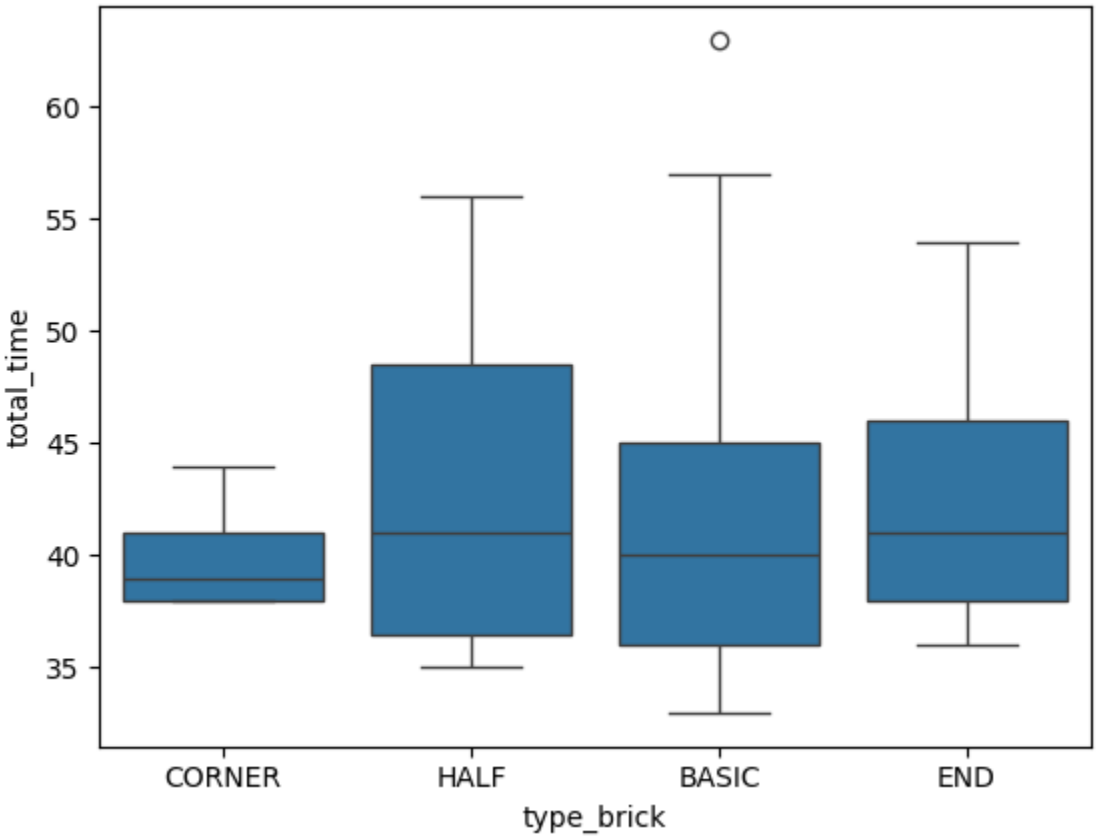


## Deskriptivní statistická analýza dat

In [7]:
```
df.describe()
```

Out[7]:

| | id | time_start_sec | time_verif_sec | time_dest_sec | time_end_sec | type | start_to_verif |
|---|---|---|---|---|---|---|---|
| **count** | 102.000000 | 102.000000 | 102.000000 | 102.000000 | 102.000000 | 102.000000 | 102.000000 |
| **mean** | 68.656863 | 53095.647059 | 53103.901961 | 53118.941176 | 53137.284314 | 1.303922 | 8.254902 |
| **std** | 36.495353 | 2852.271152 | 2852.560429 | 2851.900259 | 2851.193613 | 0.793404 | 3.204842 |
| **min** | 1.000000 | 48679.000000 | 48685.000000 | 48703.000000 | 48725.000000 | 1.000000 | 4.000000 |
| **25%** | 39.250000 | 50540.250000 | 50548.250000 | 50565.250000 | 50581.250000 | 1.000000 | 6.000000 |
| **50%** | 66.500000 | 51696.000000 | 51703.000000 | 51716.000000 | 51737.000000 | 1.000000 | 8.000000 |
| **75%** | 100.750000 | 55791.000000 | 55798.250000 | 55815.000000 | 55829.500000 | 1.000000 | 8.000000 |
| **max** | 136.000000 | 57449.000000 | 57466.000000 | 57473.000000 | 57483.000000 | 4.000000 | 20.000000 |

## Výpočet četnosti jednotlivých hodnot

In [8]:
```
df['type_brick'].value_counts()
```

Out[8]:
```
type_brick
BASIC     87
HALF       6
END        5
CORNER     4
Name: count, dtype: int64
```

In [9]:
```
df['type_brick'].value_counts().to_frame()
```

Out[9]:

| type_brick | count |
|---|---|
| **BASIC** | 87 |
| **HALF** | 6 |
| **END** | 5 |
| **CORNER** | 4 |

## Seskupování dat

In [10]:
```
df['type_brick'].unique()
```

Out[10]:
```
array(['CORNER', 'HALF', 'BASIC', 'END'], dtype=object)
```

In [11]:
```
df_group_one = df[['type_brick', 'total_time']]
df_group_one
```

Out[11]:

| | type_brick | total_time |
|---|---|---|
| **0** | CORNER | 40 |
| **1** | HALF | 38 |
| **2** | BASIC | 36 |
| **3** | BASIC | 36 |
| **4** | BASIC | 44 |
| **...** | ... | ... |
| **97** | BASIC | 41 |
| **98** | BASIC | 33 |
| **99** | BASIC | 33 |
| **100** | BASIC | 37 |
| **101** | BASIC | 34 |

102 rows × 2 columns

In [12]:
```
# Výpočet průměrné hodnoty času pro jednotlivé kategorie dat
df_group_one = df_group_one.groupby(['type_brick'], as_index=False).mean()
df_group_one
```

Out[12]:

| | type_brick | total_time |
|---|---|---|
| **0** | BASIC | 41.528736 |
| **1** | CORNER | 40.000000 |
| **2** | END | 43.000000 |
| **3** | HALF | 43.166667 |

## Vztah mezi korelací a kauzalitou

**Korelace**: míra vzájemné závislosti mezi proměnnými.

**Kauzalita**: vztah příčiny a následku mezi dvěma proměnnými.

## Pearsonova korelace

Pearsonův korelační koeficient měří lineární závislost mezi dvěma proměnnými X a Y.

Výsledný koeficient nabývá hodnot v intervalu od -1 do 1, kde:

- **1**: Dokonalá kladná lineární korelace.
- **0**: Žádná lineární korelace, proměnné se pravděpodobně lineárně neovlivňují.
- **-1**: Dokonalá záporná lineární korelace.

In [13]:
```
corr = df[['type', 'start_to_verif', 'verif_to_dest', 'dest_to_end', 'total_time']].corr()
```

In [14]:
```
# Teplotní mapa (heatmapa)
sns.set_theme(style="white")

plt.figure(figsize=(8, 6))
sns.heatmap(
    corr,
    annot=True,
    cmap="RdBu_r",
    center=0,
    linewidths=0.5
)
```

Out[14]:
```
<Axes: >
```

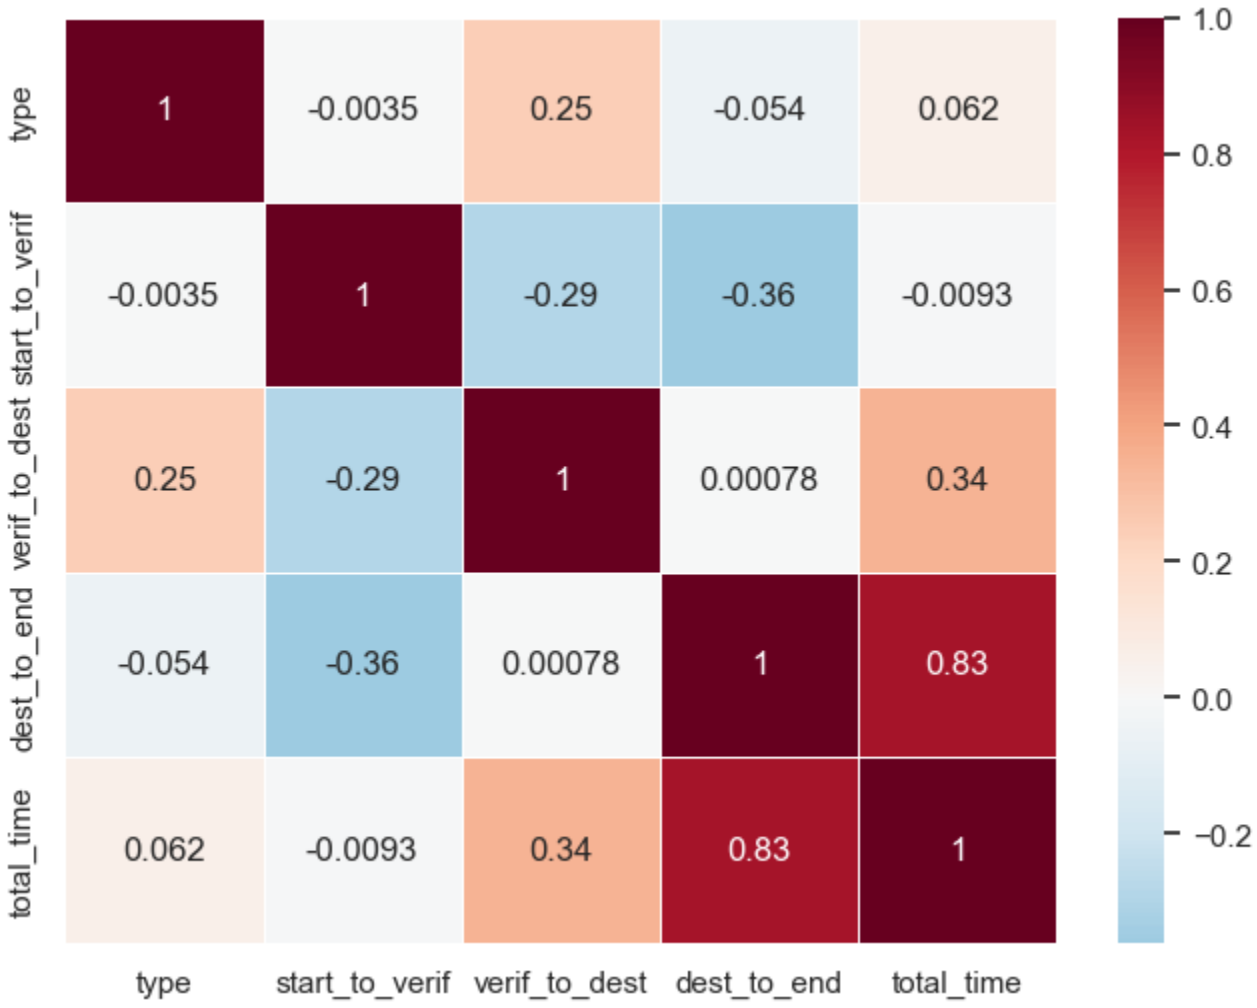


**P-value**

P-hodnota (P-value) představuje pravděpodobnost, že korelace mezi dvěma proměnnými je statisticky významná. Obvykle se volí hladina významnosti 0,05, což znamená, že s 95% jistotou považujeme korelaci mezi proměnnými za statisticky významnou.

Podle běžně používané konvence platí, že pokud:

- p-hodnota je < 0,001: existuje silný důkaz, že korelace je statisticky významná.
- p-hodnota je < 0,05: existuje středně silný důkaz, že korelace je statisticky významná.
- p-hodnota je < 0,1: existuje slabý důkaz, že korelace je statisticky významná.
- p-hodnota je > 0,1: neexistuje důkaz o statistické významnosti korelace.

### 'dest_to_end' vs. 'total_time'

In [15]:
```
# Výpočet Pearsonova korelačního koeficientu a odpovídající p-hodnoty mezi proměnnými ‚dest_to_er
pearson_coef, p_value = stats.pearsonr(df['dest_to_end'], df['total_time'])
print("Pearsonov korelační koeficient = ", pearson_coef, ".  P-value =", p_value)
```

```
Pearsonov korelační koeficient =  0.8316539386073389 .  P-value = 2.6999302925476424e-27
```

Protože p-hodnota je < 0,001, korelace mezi proměnnými ‚dest_to_end' a ‚total_time' je statisticky významná a lineární vztah je středně silný

## Analýza rozptylu (ANOVA) pro porovnání skupinových průměrů

**Analýza rozptylu (ANOVA)** je statistická metoda používaná k ověření, zda existují statisticky významné rozdíly mezi průměry dvou nebo více skupin. ANOVA vrací dva základní parametry:

**F-statistika (F-test)**: ANOVA předpokládá, že průměry všech skupin jsou stejné, a následně vyhodnocuje, jak moc se skutečné průměry od tohoto předpokladu odchylují. Tato odchylka je vyjádřena hodnotou F-statistiky. Vyšší hodnota znamená větší rozdíl mezi skupinovými průměry.

**P-hodnota**: P-hodnota udává, jak statisticky významná je vypočtená hodnota F-statistiky.

Pokud je analyzovaná proměnná silně korelována s vysvětlovanou proměnnou, očekáváme, že ANOVA vrátí vysokou hodnotu F-statistiky a nízkou p-hodnotu.

In [16]:
```
# provedeme seskupení dat podle jednotlivých kategorií
grouped_test = df[['type_brick', 'total_time']].groupby('type_brick')
grouped_test.head()
```

Out[16]:

| | type_brick | total_time |
|---|---|---|
| **0** | CORNER | 40 |
| **1** | HALF | 38 |
| **2** | BASIC | 36 |
| **3** | BASIC | 36 |
| **4** | BASIC | 44 |
| **5** | BASIC | 34 |
| **6** | BASIC | 34 |
| **10** | END | 46 |
| **21** | HALF | 36 |
| **22** | CORNER | 38 |
| **23** | HALF | 44 |
| **37** | END | 38 |
| **53** | CORNER | 44 |
| **54** | HALF | 56 |
| **64** | END | 54 |
| **78** | HALF | 35 |
| **79** | CORNER | 38 |
| **94** | END | 41 |
| **95** | END | 36 |

In [17]:
```
grouped_test.get_group('BASIC')['total_time']
```

Out[17]:
```
2      36
3      36
4      44
5      34
6      34
       ..
97     41
98     33
99     33
100    37
101    34
Name: total_time, Length: 87, dtype: int64
```

### BASIC a HALF

In [18]:
```
f_val, p_val = stats.f_oneway(grouped_test.get_group('BASIC')['total_time'], grouped_test.get_gro

print( "ANOVA results: F=", f_val, ", P =", p_val )
```

```
ANOVA results: F= 0.3421926095127691 , P = 0.5600140178204602
```

Výsledky analýzy ANOVA pro kategorie `BASIC` a `HALF` vykazují p-hodnotu vyšší než 0,1, což znamená, že F-statistika není statisticky významná. Nelze tedy zamítnout nulovou hypotézu o shodě průměrů obou skupin a nelze potvrdit statisticky významný rozdíl mezi nimi.

## Závěr: Identifikace významných proměnných

Na základě provedené analýzy byly identifikovány následující významné proměnné:

- total_time
- start_to_verif
- verif_to_dest
- dest_to_end

## Export datové sady do formátu CSV

In [19]:
```
df_ready = df[['id', 'type_brick', 'type', 'start_to_verif', 'verif_to_dest', 'dest_to_end', 'tot
```

In [20]:
```
df_ready.to_csv('../../data/raw/ready_timelaps.csv', index=False)
```

## Autor / Organizace / Datum

Vjačeslav Usmanov, ČVUT v Praze, Fakulta stavební

Přehled změn

| Datum (YYYY-MM-DD) | Verze | Autor změny | Popis změny |
|---|---|---|---|
| 2026-01-21 | 1.1 | Vjačeslav Usmanov | added DS_03_Features.ipynb |
| 2026-02-12 | 1.2 | Vjačeslav Usmanov | changed DS_03_Features.ipynb |