

Deterministic Model 03: Ověření modelu (Model Verification)

```
In [1]: # Instalace potřebných knihoven
        %%pip install pandas
        %%pip install numpy
```

```
In [2]: # Import potřebných knihoven
import pandas as pd
import numpy as np

from scipy import stats
from scipy.stats import ks_2samp, ttest_ind, mannwhitneyu

import pandas as pd
import matplotlib.pyplot as plt
```

Načtení reálných a simulačních dat

```
In [3]: # Soubor je načten a přiřazen do proměnné ,df_sim"
other_path = '../data/02_DetermModel/model_data.csv'
df_sim = pd.read_csv(other_path, header=0)
```

```
In [4]: # Zobrazení prvních 5 řádků datasetu
print('Prvních 5 řádků datového rámce')
df_sim.head(5)
```

Prvních 5 řádků datového rámce

```
Out[4]:
```

	x	y	z	dist	total_time
0	74	459	1284	2036.347957	39.408400
1	-90	4908	2217	2706.465038	42.332379
2	522	3074	26	1374.058223	36.518575
3	425	2247	2739	1504.644476	37.088373
4	516	3425	1590	1032.705670	35.029123

```
In [5]: # Základní deskriptivní statistika simulovaného datasetu
df_sim.describe()
```

Out[5]:

	x	y	z	dist	total_time
count	20000.000000	20000.000000	20000.000000	20000.000000	20000.000000
mean	1422.944700	1336.856500	1374.817600	2435.292585	41.149149
std	1440.916105	1512.725045	805.317921	1090.305852	4.757424
min	-99.000000	-99.000000	0.000000	64.101482	30.802730
25%	248.000000	202.000000	676.000000	1577.850196	37.407798
50%	599.500000	521.000000	1374.500000	2402.055568	41.004123
75%	2591.250000	2435.000000	2076.000000	3159.976186	44.311223
max	4599.000000	4949.000000	2749.000000	5026.495598	52.455566

In [6]: `# Soubor je načten a přiřazen do proměnné ,df_real"`
`other_path = '../..data/02_DetermModel/model_data_real.csv'`
`df_real = pd.read_csv(other_path, header=0)`

In [7]: `# Zobrazení prvních 5 řádků datasetu`
`print('Prvních 5 řádků datového rámce')`
`df_real.head(5)`

Prvních 5 řádků datového rámce

Out[7]:

	id	type_brick	type	rotation	x	y	z	layer	pallet	dist	start_to_verif	verif_to_dest	dest_t
0	1	CORNER	2	90	220	95	0	1	1	2731	6	17	
1	2	HALF	3	90	220	252	0	1	1	2596	3	17	
2	4	BASIC	1	90	220	690	0	1	2	2350	6	14	
3	6	BASIC	1	90	220	1190	0	1	4	1804	7	14	
4	9	BASIC	1	90	220	1940	0	1	7	1454	8	13	

In [8]: `# Základní deskriptivní statistika simulovaného datasetu`
`df_real.describe()`


Out[8]:

	id	type	rotation	x	y	z	layer	pall
count	106.000000	106.000000	106.000000	106.000000	106.000000	106.000000	106.000000	106.000000
mean	69.622642	1.292453	94.245283	1245.122642	1037.443396	379.716981	2.518868	53.386700
std	37.319586	0.780317	67.329299	1255.988586	1258.426721	272.185013	1.088740	36.333500
min	1.000000	1.000000	0.000000	95.000000	95.000000	0.000000	1.000000	1.000000
25%	39.250000	1.000000	22.500000	220.000000	220.000000	250.000000	2.000000	22.250000
50%	67.500000	1.000000	90.000000	502.500000	220.000000	250.000000	2.000000	51.500000
75%	102.750000	1.000000	180.000000	2190.000000	1565.000000	500.000000	3.000000	86.750000
max	136.000000	4.000000	180.000000	4002.000000	4440.000000	750.000000	4.000000	120.000000

In [9]: `# Graf: Hustotní rozdělení reálných, simulačních a kalibrovaných dat`
`df_sim['total_time'].plot.density(bw_method='scott', linestyle='-', linewidth=2, label='Simulační')`
`df_real['total_time'].plot.density(bw_method='scott', linestyle='-', linewidth=2, label='Reálné')`
`df_real['total_time_calc'].plot.density(bw_method='scott', linestyle='-', linewidth=2, label='Kalibrované')`

```
plt.xlabel("Doba pracovního cyklu")
plt.ylabel("Hustotní rozdělení")
plt.title('Hustotní rozdělení reálných, simulačních a kalibrovaných dat')

plt.legend()
plt.show()
```



KS test: jednostranný

Simulační data vs. normální rozdělení

```
In [10]: ### KS test: jednostranný (porovnání simulovaných dat s normálním rozdělením)
```

```
# Vzorok 1 - simulovaná data (deterministický model po kalibraci)
sample1 = df_sim['total_time'].to_numpy()

# Generování referenčního normálního rozdělení
np.random.seed(122) # nastavení semene pro reprodukovatelnost
sample_size = 500 # velikost náhodného vzorku
mean = df_sim['total_time'].mean()
std_dev = df_sim['total_time'].std()

sample2 = np.random.normal(mean, std_dev, sample_size)

# Výpočet Kolmogorova-Smirnova testu (dvouvýběrový test)
ks_statistic, p_value = stats.ks_2samp(sample1, sample2)

print(f'Kolmogorov-Smirnovova statistika: {ks_statistic}')
print(f'P-hodnota: {p_value}')

# Testování na hladině významnosti  $\alpha = 0.05$ 
alpha = 0.05

if p_value < alpha:
```

```
print("Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.")
else:
    print("Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou od
```

Kolmogorov-Smirnovova statistika: 0.05554999999999999

P-hodnota: 0.09475552301110246

Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.

KS test: oboustranný

Simulační data vs. reálná data

```
In [11]: ### KS test: oboustranný (porovnání simulačních a reálných dat)

# Vzorek 1 - simulovaná data (deterministický model po kalibraci)
sample1 = df_sim['total_time'].to_numpy()

# Vzorek 2 - reálná měřená data
sample2 = df_real['total_time'].to_numpy()

# Výpočet oboustranného Kolmogorovova-Smirnovova testu
ks_statistic, p_value = stats.ks_2samp(sample1, sample2)

print(f'Kolmogorov-Smirnovova statistika: {ks_statistic}')
print(f'P-hodnota: {p_value}')

# Testování na hladině významnosti  $\alpha = 0.05$ 
alpha = 0.05

if p_value < alpha:
    print("Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.")
else:
    print("Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou od
```

Kolmogorov-Smirnovova statistika: 0.1811179245283019

P-hodnota: 0.0017402036207236904

Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.

KS test: oboustranný

Simulační data vs. kalibrovaná data

```
In [12]: ### KS test: oboustranný (porovnání simulačních a kalibrovaných dat)

# Vzorek 1 - simulovaná data (deterministický model po kalibraci)
sample1 = df_sim['total_time'].to_numpy()

# Vzorek 2 - reálná měřená data
sample2 = df_real['total_time_calc'].to_numpy()

# Výpočet oboustranného Kolmogorovova-Smirnovova testu
ks_statistic, p_value = stats.ks_2samp(sample1, sample2)

print(f'Kolmogorov-Smirnovova statistika: {ks_statistic}')
print(f'P-hodnota: {p_value}')

# Testování na hladině významnosti  $\alpha = 0.05$ 
alpha = 0.05

if p_value < alpha:
    print("Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.")
else:
```

```
print("Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou oc
```

Kolmogorov-Smirnovova statistika: 0.08858018867924529

P-hodnota: 0.3609793007224703

Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.

Monte Carlo Validation: Opakované podvzorkování na velikost reality

```
In [13]: # Bootstrap vzorkování ze simulace na velikost reálného datasetu
n_real = len(df_real)

sim_samples = []

for _ in range(1000):
    sample = df_sim.sample(n=n_real, replace=True, random_state=122 + _)
    sim_samples.append(sample['total_time'])
```

KS test pro každé podvzorkování (Reálná data)

```
In [14]: # Výpočet KS p-hodnot pro porovnání reálných a simulovaných dat
p_vals = []

for s in sim_samples:
    _, p = ks_2samp(df_real['total_time'], s)
    p_vals.append(p)
```

Pravděpodobnost shody modelu

```
In [15]: valid_ratio = np.mean(np.array(p_vals) > 0.05)

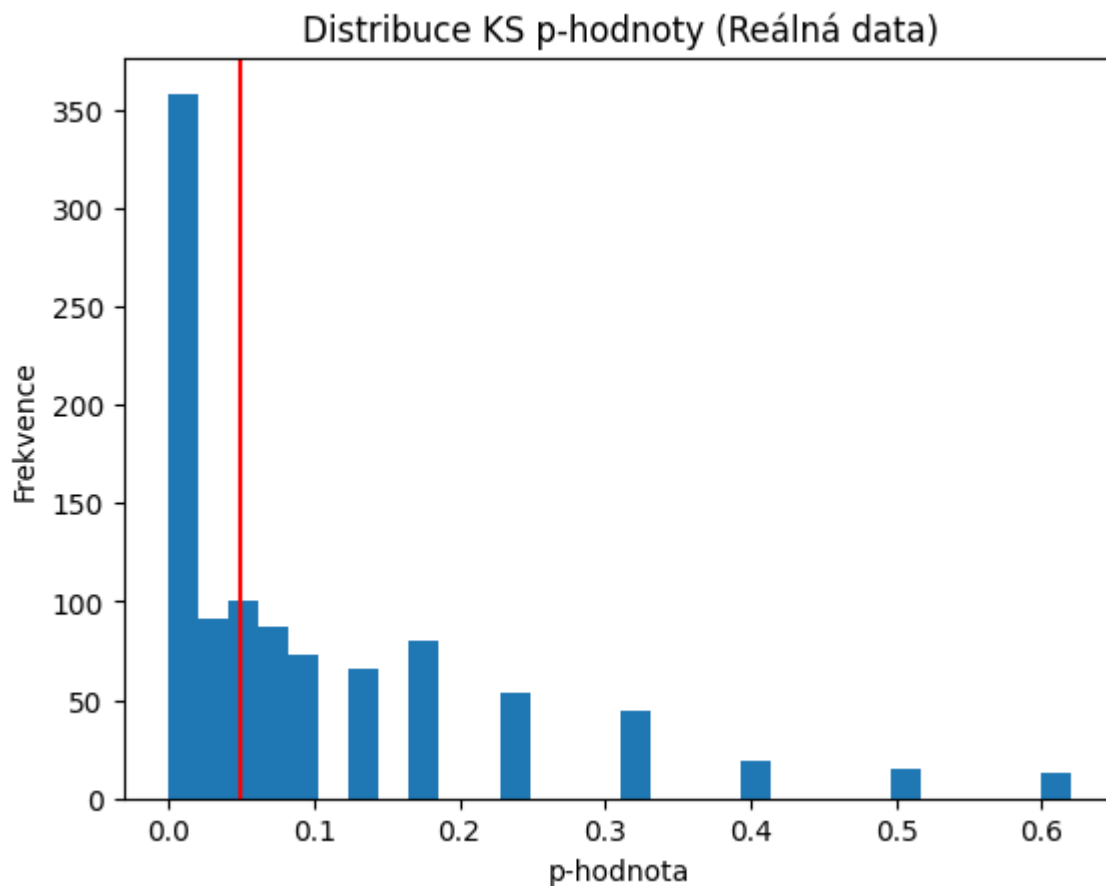
print("Podíl validních simulací (Reálná data):", valid_ratio)
```

Podíl validních simulací (Reálná data): 0.451

Distribuce KS p-hodnoty (Reálná data)

```
In [16]: plt.figure()
plt.hist(p_vals, bins=30)
plt.axvline(0.05, color='red')

plt.title("Distribuce KS p-hodnoty (Reálná data)")
plt.xlabel("p-hodnota")
plt.ylabel("Frekvence")
plt.show()
```



KS test pro každé podvzorkování (Kalibrovaná data)

```
In [17]: # Výpočet KS p-hodnot pro porovnání reálných a simulovaných dat
p_vals = []

for s in sim_samples:
    _, p = ks_2samp(df_real['total_time_calc'], s)
    p_vals.append(p)
```

Pravděpodobnost shody modelu

```
In [18]: valid_ratio = np.mean(np.array(p_vals) > 0.05)

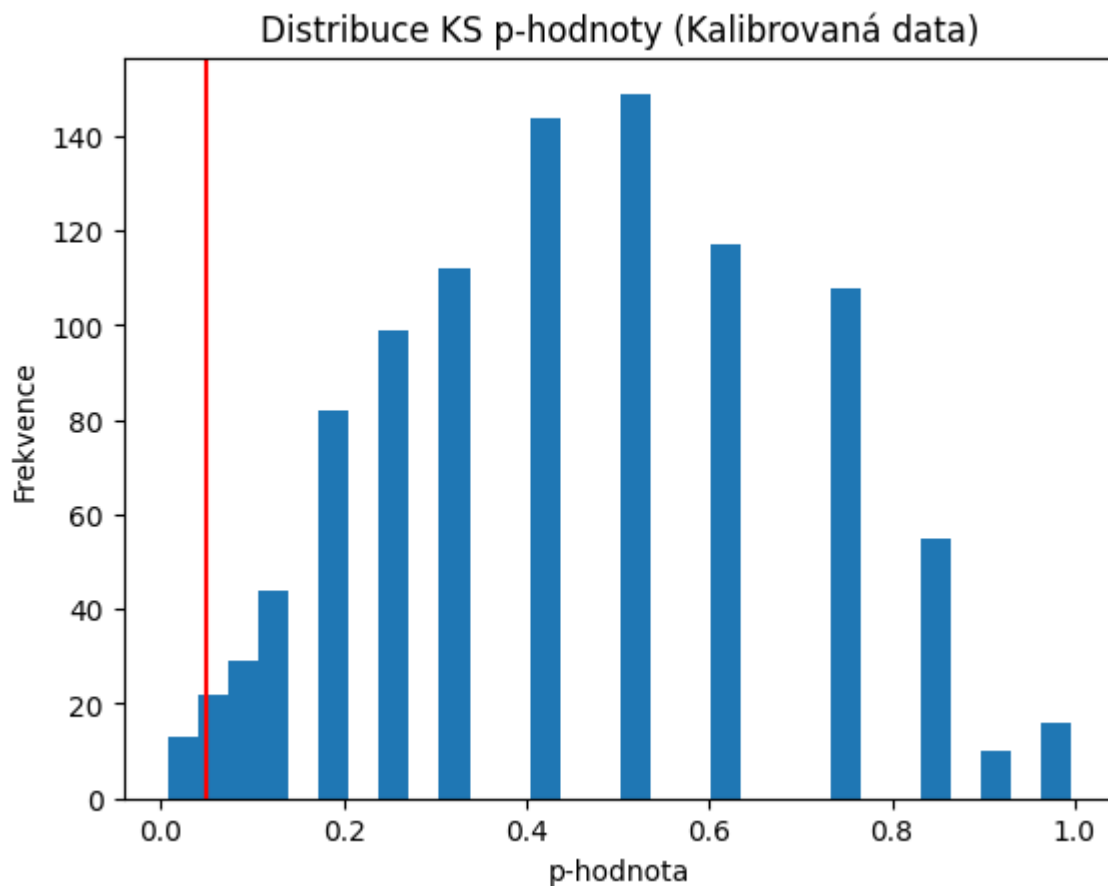
print("Podíl validních simulací (Kalibrovaná data):", valid_ratio)
```

Podíl validních simulací (Kalibrovaná data): 0.983

Distribuce KS p-hodnoty (Kalibrovaná data)

```
In [19]: plt.figure()
plt.hist(p_vals, bins=30)
plt.axvline(0.05, color='red')

plt.title("Distribuce KS p-hodnoty (Kalibrovaná data)")
plt.xlabel("p-hodnota")
plt.ylabel("Frekvence")
plt.show()
```



Porovnání průměru a směrodatné odchylky

In [20]: *# Porovnání simulovaných a reálných dat*

Výpočet průměrných hodnot

```
mean_sim = df_sim['total_time'].mean()
```

```
mean_real = df_real['total_time'].mean()
```

Výpočet směrodatných odchylek

```
std_sim = df_sim['total_time'].std()
```

```
std_real = df_real['total_time'].std()
```

Relativní odchylka průměrů

```
mean_diff = abs(mean_sim - mean_real) / abs(mean_real)
```

Poměr směrodatných odchylek

```
std_ratio = std_sim / std_real
```

Relativní odchylka směrodatných odchylek

```
std_diff_rela = abs(std_sim - std_real) / abs(std_real)
```

```
print(f'Relativní odchylka průměrů: {mean_diff * 100:.2f}%')
```

```
print(f'Poměr směrodatných odchylek: {std_ratio:.4f}%')
```

```
print(f'Relativní odchylka směrodatných odchylek: {std_diff_rela * 100:.2f}%')
```

```
alpha = 0.05
```

```
if mean_diff > alpha:
```

```
    print('Relativní odchylka průměrů přesahuje zvolenou hranici  $\alpha$ .')
```

```
else:
```

```
    print('Relativní odchylka průměrů nepřesahuje zvolenou hranici  $\alpha$ .')
```

Relativní odchylka průměrů: 0.46%
Poměr směrodatných odchylek: 0.7481
Relativní odchylka směrodatných odchylek: 25.19%
Relativní odchylka průměrů nepřesahuje zvolenou hranici α .

```
In [21]: # Porovnání simulovaných a kalibrovaných dat

# Výpočet průměrných hodnot
mean_sim = df_sim['total_time'].mean()
mean_real = df_real['total_time_calc'].mean()

# Výpočet směrodatných odchylek
std_sim = df_sim['total_time'].std()
std_real = df_real['total_time_calc'].std()

# Relativní odchylka průměrů
mean_diff = abs(mean_sim - mean_real) / abs(mean_real)

# Poměr směrodatných odchylek
std_ratio = std_sim / std_real

# Relativní odchylka směrodatných odchylek
std_diff_rela = abs(std_sim - std_real) / abs(std_real)

print(f'Relativní odchylka průměrů: {mean_diff * 100:.2f}%')
print(f'Poměr směrodatných odchylek: {std_ratio:.4f}')
print(f'Relativní odchylka směrodatných odchylek: {std_diff_rela * 100:.2f}%')

alpha = 0.05

if mean_diff > alpha:
    print('Relativní odchylka průměrů přesahuje zvolenou hranici  $\alpha$ .')
else:
    print('Relativní odchylka průměrů nepřesahuje zvolenou hranici  $\alpha$ .')
```

Relativní odchylka průměrů: 0.46%
Poměr směrodatných odchylek: 1.2605
Relativní odchylka směrodatných odchylek: 26.05%
Relativní odchylka průměrů nepřesahuje zvolenou hranici α .

Parametrické porovnání dat

```
In [22]: def parametric_verification(
    s1: pd.Series,
    s2: pd.Series,
    alpha: float = 0.05,
    equal_var_test: str = "levene",
    normality_test: str = "shapiro"
):
    """
    Parametrická verifikace dvou datových souborů (pandas Series).

    Testuje:
        1) normalitu rozdělení
        2) shodu rozptylů
        3) rozdíl středních hodnot (t-test)
        4) velikost efektu (Cohenovo d)

    Parametry:
        s1, s2 : porovnávané datové série
        alpha : hladina významnosti
        equal_var_test : metoda testu shody rozptylů ("levene")
        normality_test : metoda testu normality ("shapiro")
    """
```



```

Návrat:
    dict s výsledky testů
"""

result = {}

# 1. Test normality (Shapiro-Wilk)
if normality_test == "shapiro":
    n1 = stats.shapiro(s1)
    n2 = stats.shapiro(s2)

result["normality"] = {
    "s1_p": n1.pvalue,
    "s2_p": n2.pvalue,
    "normal": (n1.pvalue > alpha) and (n2.pvalue > alpha)
}

# 2. Test shody rozptylů (Levene)
if equal_var_test == "levene":
    var_test = stats.levene(s1, s2)

result["variance"] = {
    "p_value": var_test.pvalue,
    "equal": var_test.pvalue > alpha
}

# 3. Dvouvýběrový t-test
equal_var = result["variance"]["equal"]

t = stats.ttest_ind(s1, s2, equal_var=equal_var)

result["ttest"] = {
    "t_stat": t.statistic,
    "p_value": t.pvalue,
    "different_mean": t.pvalue < alpha
}

# 4. Velikost efektu (Cohenovo d)
pooled_std = np.sqrt(
    ((s1.std() ** 2) + (s2.std() ** 2)) / 2
)

# ochrana proti dělení nulou
if pooled_std == 0:
    cohen_d = 0
else:
    cohen_d = (s1.mean() - s2.mean()) / pooled_std

result["effect_size"] = {
    "cohen_d": cohen_d
}

return result

```

```

In [23]: result = parametric_verification(df_sim['total_time'], df_real['total_time_calc'])
print(f"""
Normalita:
    s1 p-value: {result['normality']['s1_p']:.5f}
    s2 p-value: {result['normality']['s2_p']:.5f}
    Normalita splněna: {result['normality']['normal']}

Shoda rozptylů:

```

```

p-value: {result['variance']['p_value']:.5f}
Rozptyly shodné: {result['variance']['equal']}

T-test:
t-statistika: {result['ttest']['t_stat']:.5f}
p-value: {result['ttest']['p_value']:.5f}
Rozdíl průměrů významný: {result['ttest']['different_mean']}

Velikost efektu:
Cohen d: {result['effect_size']['cohen_d']:.4f}
"""

```

Normalita:

```

s1 p-value: 0.00000
s2 p-value: 0.09970
Normalita splněna: False

```

Shoda rozptylů:

```

p-value: 0.00223
Rozptyly shodné: False

```

T-test:

```

t-statistika: 0.50766
p-value: 0.61274
Rozdíl průměrů významný: False

```

Velikost efektu:

```

Cohen d: 0.0435

```

```

c:\Users\Vjačeslav Usmanov\AppData\Local\Programs\Python\Python311\Lib\site-packages\scipy\sta
ts\_axis_nan_policy.py:592: UserWarning: scipy.stats.shapiro: For N > 5000, computed p-value m
ay not be accurate. Current N is 20000.
res = hypotest_fun_out(*samples, **kws)

```

```

In [24]: result = parametric_verification(df_sim['total_time'], df_real['total_time'])
print(f"""
Normalita:
s1 p-value: {result['normality']['s1_p']:.5f}
s2 p-value: {result['normality']['s2_p']:.5f}
Normalita splněna: {result['normality']['normal']}

Shoda rozptylů:
p-value: {result['variance']['p_value']:.5f}
Rozptyly shodné: {result['variance']['equal']}

T-test:
t-statistika: {result['ttest']['t_stat']:.5f}
p-value: {result['ttest']['p_value']:.5f}
Rozdíl průměrů významný: {result['ttest']['different_mean']}

Velikost efektu:
Cohen d: {result['effect_size']['cohen_d']:.4f}
"""
)

```

Normalita:

s1 p-value: 0.00000

s2 p-value: 0.00011

Normalita splněna: False

Shoda rozptylů:

p-value: 0.00001

Rozptyly shodné: False

T-test:

t-statistika: 0.30213

p-value: 0.76315

Rozdíl průměrů významný: False

Velikost efektu:

Cohen d: 0.0333

```
In [25]: # Neparametrický Mann-Whitneyův U test (oboustranný)
# Testuje, zda se dvě nezávislé skupiny statisticky významně liší
# v centrální tendenci (mediánu).
```

```
stats.mannwhitneyu(
    df_sim['total_time'],
    df_real['total_time_calc'],
    alternative='two-sided'
)
```

```
Out[25]: MannwhitneyuResult(statistic=np.float64(1071152.0), pvalue=np.float64(0.8515793385227874))
```

```
In [26]: # Neparametrický Mann-Whitneyův U test (oboustranný)
# Testuje, zda se dvě nezávislé skupiny statisticky významně liší
# v centrální tendenci (mediánu).
```

```
stats.mannwhitneyu(
    df_sim['total_time'],
    df_real['total_time'],
    alternative='two-sided'
)
```

```
Out[26]: MannwhitneyuResult(statistic=np.float64(1137262.0), pvalue=np.float64(0.1948652940712411))
```

Vyhodnocení shody simulovaných a kalibrovaných dat

Test normality (Shapiro–Wilk)

s1 p-value = 0.00000

s2 p-value = 0.09970

Normalita splněna: False

Interpretace:

Simulační data (s1) nesplňují předpoklad normality.

Reálná data (s2) jsou na hranici ($p \approx 0,099$), ale při $\alpha = 0,05$ normalitu nelze zamítnout.

Celkově tedy nelze předpokládat normalitu obou souborů.

Parametrický t-test je zde metodicky hraniční, proto je vhodné použít i neparametrický test (Mann–Whitney)

Shoda rozptylů (Levene)

p-value = 0.00223

Rozptyly shodné: False

Interpretace:

Rozptyly obou souborů se statisticky významně liší.

To potvrzuje strukturální rozdíl variability mezi simulovanými a reálnými daty.

t-test (porovnání průměrů)

t-statistika ≈ 0.50766

p-value = 0.61274

Rozdíl průměrů významný: False

Interpretace:

$p \gg 0,05 \rightarrow$ nelze zamítnout nulovou hypotézu.

Průměrné hodnoty obou souborů jsou velmi podobné.

Kalibrace modelu byla velmi účinná.

Velikost efektu (Cohen d)

Cohen d = 0.0033

Interpretace:

Hodnota je prakticky nulová.

Efekt je zanedbatelný.

Mann–Whitney U test (neparametrický)

p-value ≈ 0.8515

Interpretace:

$p \gg 0,05 \rightarrow$ nelze zamítnout nulovou hypotézu.

Mediány obou rozdělení se statisticky významně neliší.

Neparametrický test potvrzuje závěr t-testu.

Autor / Organizace / Datum

Vjačeslav Usmanov, ČVUT v Praze, Fakulta stavební

Přehled změn

Datum (YYYY-MM-DD)	Verze	Autor změny	Popis změny
2026-01-25	1.1	Vjačeslav Usmanov	added DM_03_Model_Verification.ipynb
2026-02-14	1.2	Vjačeslav Usmanov	changed DM_03_Model_Verification.ipynb