

# Deterministic Model 03: Ověření modelu (Model Verification)

```
In [1]: # Instalace potřebných knihoven  
#%pip install pandas  
#%pip install numpy
```

```
In [2]: # Import potřebných knihoven  
import pandas as pd  
import numpy as np  
  
from scipy import stats  
  
import pandas as pd  
import matplotlib.pyplot as plt
```

## Načtení reálných a simulačních dat

```
In [3]: # Soubor je načten a přiřazen do proměnné ,df_sim"  
other_path = '../..../data/sim/model_data.csv'  
df_sim = pd.read_csv(other_path, header=0)
```

```
In [4]: # Zobrazení prvních 5 řádků datasetu  
print('Prvních 5 řádků datového rámce')  
df_sim.head(5)
```

Prvních 5 řádků datového rámce

```
Out[4]:      x      y      z      dist  total_time  
0    74    459   1284  2036.347957  39.870016  
1   -90   4908   2217  2706.465038  42.842716  
2    522   3074     26  1374.058223  36.932040  
3    425   2247   2739  1504.644476  37.511332  
4    516   3425   1590  1032.705670  35.417769
```

```
In [5]: # Základní deskriptivní statistika simulovaného datasetu  
df_sim.describe()
```

Out[5]:

	x	y	z	dist	total_time
count	20000.000000	20000.000000	20000.000000	20000.000000	20000.000000
mean	1422.944700	1336.856500	1374.817600	2435.292585	41.639771
std	1440.916105	1512.725045	805.317921	1090.305852	4.836695
min	-99.000000	-99.000000	0.000000	64.101482	31.120954
25%	248.000000	202.000000	676.000000	1577.850196	37.836079
50%	599.500000	521.000000	1374.500000	2402.055568	41.492328
75%	2591.250000	2435.000000	2076.000000	3159.976186	44.854532
max	4599.000000	4949.000000	2749.000000	5026.495598	53.134580

In [6]: # Soubor je načten a přiřazen do proměnné ,df\_real"  
other\_path = '../data/sim/model\_data\_real.csv'  
df\_real = pd.read\_csv(other\_path, header=0)

In [7]: # Zobrazení prvních 5 řádků datasetu  
print('Prvních 5 řádků datového rámce')  
df\_real.head(5)

Prvních 5 řádků datového rámce

	id	type_brick	type	rotation	x	y	z	layer	pallet	dist	start_to_verif	verif_to_dest	dest_to_end
0	1	CORNER	2	90	220	95	0	1	1	2731	6	18	
1	2	HALF	3	90	220	252	0	1	1	2596	4	16	
2	4	BASIC	1	90	220	690	0	1	2	2350	6	14	
3	6	BASIC	1	90	220	1190	0	1	4	1804	6	14	
4	9	BASIC	1	90	220	1940	0	1	7	1454	8	12	

In [8]: # Základní deskriptivní statistika simulovaného datasetu  
df\_real.describe()

	id	type	rotation	x	y	z	layer	pallet
count	102.000000	102.000000	102.000000	102.000000	102.000000	102.000000	102.000000	102.000000
mean	68.656863	1.303922	93.529412	1280.715686	999.303922	372.549020	2.490196	52.254902
std	36.495353	0.793404	68.109508	1266.664204	1249.772588	267.332575	1.069330	35.606676
min	1.000000	1.000000	0.000000	95.000000	95.000000	0.000000	1.000000	1.000000
25%	39.250000	1.000000	0.000000	220.000000	220.000000	250.000000	2.000000	22.250000
50%	66.500000	1.000000	90.000000	565.000000	220.000000	250.000000	2.000000	50.500000
75%	100.750000	1.000000	180.000000	2283.750000	1533.750000	500.000000	3.000000	84.750000
max	136.000000	4.000000	180.000000	4002.000000	4440.000000	750.000000	4.000000	120.000000

In [9]: # Graf: Hustotní rozdělení reálných, simulačních a kalibrovaných dat


```

df_sim['total_time'].plot.density(bw_method='scott', linestyle='--', linewidth=2, label='Simulační')
df_real['total_time'].plot.density(bw_method='scott', linestyle='--', linewidth=2, label='Reálná')
df_real['total_time_calc'].plot.density(bw_method='scott', linestyle='--', linewidth=2, label='Kalibrovaná')

plt.xlabel("Doba pracovního cyklu")
plt.ylabel("Hustotní rozdělení")
plt.title('Hustotní rozdělení reálných, simulačních a kalibrovaných dat')

plt.legend()
plt.show()

```



## KS test: jednostranný

Simulační data vs. normální rozdělení

In [10]: *### KS test: jednostranný (porovnání simulovaných dat s normálním rozdělením)*

```

# Vzorek 1 - simulovaná data (deterministický model po kalibraci)
sample1 = df_sim['total_time'].to_numpy()

# Generování referenčního normálního rozdělení
np.random.seed(122)           # nastavení semene pro reprodukovatelnost
sample_size = 500             # velikost náhodného vzorku
mean = df_sim['total_time'].mean()
std_dev = df_sim['total_time'].std()

sample2 = np.random.normal(mean, std_dev, sample_size)

# Výpočet Kolmogorovova-Smirnovova testu (dvouvýběrový test)
ks_statistic, p_value = stats.ks_2samp(sample1, sample2)

print(f'Kolmogorov-Smirnovova statistika: {ks_statistic}')

```

```
print(f'P-hodnota: {p_value}')

# Testování na hladině významnosti  $\alpha = 0.05$ 
alpha = 0.05

if p_value < alpha:
    print("Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.")
else:
    print("Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.")
```

Kolmogorov-Smirnovova statistika: 0.05554999999999999

P-hodnota: 0.09475552301110246

Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.

## KS test: oboustranný

Simulační data vs. reálná data

In [11]: *### KS test: oboustranný (porovnání simulačních a reálných dat)*

```
# Vzorek 1 - simulovaná data (deterministický model po kalibraci)
sample1 = df_sim['total_time'].to_numpy()

# Vzorek 2 - reálná měřená data
sample2 = df_real['total_time'].to_numpy()

# Výpočet oboustraného Kolmogorovova-Smirnovova testu
ks_statistic, p_value = stats.ks_2samp(sample1, sample2)

print(f'Kolmogorov-Smirnovova statistika: {ks_statistic}')
print(f'P-hodnota: {p_value}')

# Testování na hladině významnosti  $\alpha = 0.05$ 
alpha = 0.05

if p_value < alpha:
    print("Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.")
else:
    print("Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.")
```

Kolmogorov-Smirnovova statistika: 0.17172254901960787

P-hodnota: 0.004492681629376993

Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.

## KS test: oboustranný

Simulační data vs. kalibrovaná data

In [12]: *### KS test: oboustranný (porovnání simulačních a kalibrovaných dat)*

```
# Vzorek 1 - simulovaná data (deterministický model po kalibraci)
sample1 = df_sim['total_time'].to_numpy()

# Vzorek 2 - reálná měřená data
sample2 = df_real['total_time_calc'].to_numpy()

# Výpočet oboustraného Kolmogorovova-Smirnovova testu
ks_statistic, p_value = stats.ks_2samp(sample1, sample2)
```

```

print(f'Kolmogorov-Smirnovova statistika: {ks_statistic}')
print(f'P-hodnota: {p_value}')

# Testování na hladině významnosti  $\alpha = 0.05$ 
alpha = 0.05

if p_value < alpha:
    print("Zamítáme nulovou hypotézu. Vzorky pocházejí z různých rozdělení.")
else:
    print("Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.")

```

Kolmogorov-Smirnovova statistika: 0.0965343137254902

P-hodnota: 0.2847117830146836

Nezamítáme nulovou hypotézu. Není dostatek důkazů pro tvrzení, že rozdělení jsou odlišná.

## Porovnání průměru a směrodatné odchyly

In [13]: # Porovnání simulovaných a reálných dat

```

# Výpočet průměrných hodnot
mean_sim = df_sim['total_time'].mean()
mean_real = df_real['total_time'].mean()

# Výpočet směrodatných odchylek
std_sim = df_sim['total_time'].std()
std_real = df_real['total_time'].std()

# Relativní odchylka průměrů
mean_diff = abs(mean_sim - mean_real) / abs(mean_real)

# Poměr směrodatných odchylek
std_ratio = std_sim / std_real

# Relativní odchylka směrodatných odchylek
std_diff_rela = abs(std_sim - std_real) / abs(std_real)

print(f'Relativní odchylka průměrů: {mean_diff * 100:.2f}%')
print(f'Poměr směrodatných odchylek: {std_ratio:.4f}')
print(f'Relativní odchylka směrodatných odchylek: {std_diff_rela * 100:.2f}%')

alpha = 0.05

if mean_diff > alpha:
    print('Relativní odchylka průměrů přesahuje zvolenou hranici  $\alpha$ .')
else:
    print('Relativní odchylka průměrů nepřesahuje zvolenou hranici  $\alpha$ .')

```

Relativní odchylka průměrů: 0.01%

Poměr směrodatných odchylek: 0.7437

Relativní odchylka směrodatných odchylek: 25.63%

Relativní odchylka průměrů nepřesahuje zvolenou hranici  $\alpha$ .

In [14]: # Porovnání simulovaných a kalibrovaných dat

```

# Výpočet průměrných hodnot
mean_sim = df_sim['total_time'].mean()
mean_real = df_real['total_time_calc'].mean()

# Výpočet směrodatných odchylek
std_sim = df_sim['total_time'].std()

```

```

std_real = df_real['total_time_calc'].std()

# Relativní odchylka průměrů
mean_diff = abs(mean_sim - mean_real) / abs(mean_real)

# Poměr směrodatných odchylek
std_ratio = std_sim / std_real

# Relativní odchylka směrodatných odchylek
std_diff_rela = abs(std_sim - std_real) / abs(std_real)

print(f'Relativní odchylka průměrů: {mean_diff * 100:.2f}%')
print(f'Poměr směrodatných odchylek: {std_ratio:.4f}')
print(f'Relativní odchylka směrodatných odchylek: {std_diff_rela * 100:.2f}%')

alpha = 0.05

if mean_diff > alpha:
    print('Relativní odchylka průměrů přesahuje zvolenou hranici α.')
else:
    print('Relativní odchylka průměrů nepřesahuje zvolenou hranici α.')

```

Relativní odchylka průměrů: 0.01%  
 Poměr směrodatných odchylek: 1.2884  
 Relativní odchylka směrodatných odchylek: 28.84%  
 Relativní odchylka průměrů nepřesahuje zvolenou hranici α.

## Parametrické porovnání dat

In [15]:

```

def parametric_verification(
    s1: pd.Series,
    s2: pd.Series,
    alpha: float = 0.05,
    equal_var_test: str = "levene",
    normality_test: str = "shapiro"
):
    """
    Parametrická verifikace dvou datových souborů (pandas Series).

    Testuje:
        1) normalitu rozdělení
        2) shodu rozptylů
        3) rozdíl středních hodnot (t-test)
        4) velikost efektu (Cohenovo d)

    Parametry:
        s1, s2 : porovnávané datové série
        alpha : hladina významnosti
        equal_var_test : metoda testu shody rozptylů ("levene")
        normality_test : metoda testu normality ("shapiro")

    Návrat:
        dict s výsledky testů
    """

    result = {}

    # 1. Test normality (Shapiro-Wilk)
    if normality_test == "shapiro":
        n1 = stats.shapiro(s1)

```

```

n2 = stats.shapiro(s2)

result["normality"] = {
    "s1_p": n1.pvalue,
    "s2_p": n2.pvalue,
    "normal": (n1.pvalue > alpha) and (n2.pvalue > alpha)
}

# 2. Test shody rozptylu (Levene)
if equal_var_test == "levene":
    var_test = stats.levene(s1, s2)

result["variance"] = {
    "p_value": var_test.pvalue,
    "equal": var_test.pvalue > alpha
}

# 3. Dvouvýběrový t-test
equal_var = result["variance"]["equal"]

t = stats.ttest_ind(s1, s2, equal_var=equal_var)

result["ttest"] = {
    "t_stat": t.statistic,
    "p_value": t.pvalue,
    "different_mean": t.pvalue < alpha
}

# 4. Velikost efektu (Cohenovo d)
pooled_std = np.sqrt(
    ((s1.std() ** 2) + (s2.std() ** 2)) / 2
)

# ochrana proti dělení nulou
if pooled_std == 0:
    cohen_d = 0
else:
    cohen_d = (s1.mean() - s2.mean()) / pooled_std

result["effect_size"] = {
    "cohen_d": cohen_d
}

return result

```

```

In [16]: result = parametric_verification(df_sim['total_time'], df_real['total_time_calc'])
print(f"""
Normalita:
s1 p-value: {result['normality']['s1_p']:.5f}
s2 p-value: {result['normality']['s2_p']:.5f}
Normalita splněna: {result['normality']['normal']}

Shoda rozptylu:
p-value: {result['variance']['p_value']:.5f}
Rozptyly shodné: {result['variance']['equal']}

T-test:
t-statistika: {result['ttest']['t_stat']:.5f}
p-value: {result['ttest']['p_value']:.5f}
Rozdíl průměrů významný: {result['ttest']['different_mean']}

```

```
Velikost efektu:  
    Cohen d: {result['effect_size']['cohen_d']:.4f}  
"""")
```

Normalita:

```
s1 p-value: 0.00000  
s2 p-value: 0.05968  
Normalita splněna: False
```

Shoda rozptylů:

```
p-value: 0.00121  
Rozptyly shodné: False
```

T-test:

```
t-statistika: 0.00674  
p-value: 0.99464  
Rozdíl průměrů významný: False
```

Velikost efektu:

```
Cohen d: 0.0006
```

```
c:\Users\usman\AppData\Local\Programs\Python\Python311\Lib\site-packages\scipy\stats\_axis_nan_policy.py:573: UserWarning: scipy.stats.shapiro: For N > 5000, computed p-value may not be accurate  
. Current N is 20000.  
    res = hypotest_fun_out(*samples, **kwds)
```

```
In [17]: result = parametric_verification(df_sim['total_time'], df_real['total_time'])  
print(f"""  
Normalita:  
    s1 p-value: {result['normality']['s1_p']:.5f}  
    s2 p-value: {result['normality']['s2_p']:.5f}  
    Normalita splněna: {result['normality']['normal']}  
Shoda rozptylů:  
    p-value: {result['variance']['p_value']:.5f}  
    Rozptyly shodné: {result['variance']['equal']}  
T-test:  
    t-statistika: {result['ttest']['t_stat']:.5f}  
    p-value: {result['ttest']['p_value']:.5f}  
    Rozdíl průměrů významný: {result['ttest']['different_mean']}  
Velikost efektu:  
    Cohen d: {result['effect_size']['cohen_d']:.4f}  
"""")
```

Normalita:  
s1 p-value: 0.00000  
s2 p-value: 0.00001  
Normalita splněna: False

Shoda rozptylů:  
p-value: 0.00003  
Rozptyly shodné: False

T-test:  
t-statistika: 0.00390  
p-value: 0.99689  
Rozdíl průměrů významný: False

Velikost efektu:  
Cohen d: 0.0004

```
In [18]: # Neparametrický Mann-Whitneyův U test (oboustranný)
# Testuje, zda se dvě nezávislé skupiny statisticky významně liší
# v centrální tendenci (mediánu).
```

```
stats.mannwhitneyu(
    df_sim['total_time'],
    df_real['total_time_calc'],
    alternative='two-sided'
)
```

```
Out[18]: MannwhitneyuResult(statistic=1006393.0, pvalue=0.8159547753469945)
```

```
In [19]: # Neparametrický Mann-Whitneyův U test (oboustranný)
# Testuje, zda se dvě nezávislé skupiny statisticky významně liší
# v centrální tendenci (mediánu).
```

```
stats.mannwhitneyu(
    df_sim['total_time'],
    df_real['total_time'],
    alternative='two-sided'
)
```

```
Out[19]: MannwhitneyuResult(statistic=1086340.0, pvalue=0.2564613491679515)
```

## Vyhodnocení shody simulovaných a kalibrovaných dat

---

### Test normality (Shapiro–Wilk)

s1 p-value = 0.00000

s2 p-value = 0.05968

Normalita splněna: False

*Interpretace:*

Simulační data (s1) nesplňují předpoklad normality.

Reálná data (s2) jsou na hranici ( $p \approx 0,06$ ), ale při  $\alpha = 0,05$  normalitu nelze zamítnout.

Celkově tedy nelze předpokládat normalitu obou souborů.

Parametrický t-test je zde metodicky hraniční, proto je vhodné použít i neparametrický test (Mann–Whitney)

---

### **Shoda rozptylů (Levene)**

p-value = 0.00121

Rozptyly shodné: False

*Interpretace:*

Rozptyly obou souborů se statisticky významně liší.

To potvrzuje strukturální rozdíl variability mezi simulovanými a reálnými daty.

---

### **t-test (porovnání průměrů)**

t-statistika  $\approx 0.0067$

p-value = 0.99464

Rozdíl průměrů významný: False

*Interpretace:*

$p \gg 0,05 \rightarrow$  nelze zamítnout nulovou hypotézu.

Průměrné hodnoty obou souborů jsou prakticky totožné.

Kalibrace modelu byla velmi účinná.

---

### **Velikost efektu (Cohen d)**

Cohen d = 0.0006

*Interpretace:*

Hodnota je prakticky nulová.

Efekt je zanedbatelný.

---

### **Mann–Whitney U test (neparametrický)**

p-value  $\approx 0.816$

*Interpretace:*

$p \gg 0,05 \rightarrow$  nelze zamítnout nulovou hypotézu.

Mediány obou rozdělení se statisticky významně neliší.

Neparametrický test potvrzuje závěr t-testu.

## Autor / Organizace / Datum

Vjačeslav Usmanov, ČVUT v Praze, Fakulta stavební

Přehled změn

Datum (YYYY-MM-DD)	Verze	Autor změny	Popis změny
2026-01-25	1.1	Vjačeslav Usmanov	added DM_03_Model_Verification.ipynb
2026-02-14	1.2	Vjačeslav Usmanov	changed DM_03_Model_Verification.ipynb